


LABELLISEZ ET APPLIQUEZ DES APPROCHES SEMI-SUPERVISÉES EN TRAITEMENT D'IMAGES

E. Houdin juillet 2026



OBJECTIF ET ORGANISATION

- 1- Explorer les images (IRM cérébrales) et extraire des caractéristiques visuelles via un modèle pré-entraîné ;
- 2- Appliquer des méthodes de clustering pour identifier des structures ou regroupements dans les données ;
- 3- Mettre en œuvre une méthode d'apprentissage semi-supervisé à partir des quelques étiquettes disponibles ;
- 4- Synthétiser vos résultats, formuler des recommandations, et les présenter à votre équipe projet.








EXPLORER LES IMAGES

- 100 images labellisées (50 images de cerveaux normaux et 50 de cerveaux avec cancer) et 108 images non labellisées mais triées par vue
- 1298 images non-labellisées
- 4 profiles : haut, arrière, gauche, droite
- Format : 512 * 512 en monochrome 3 canaux

Normal brain labelled dataset




0161f9bf-fa93-4d02-80c1-8450c8066402.jpg 314825cf-330835d472.jpg 47029726-d48794e.jpg 10548998-2ef84f03.jpg 975f-007c4fcb84a3.jpg



EXTRAIRE DES CARACTÉRISTIQUES VISUELLES

- Analyse labels et vues

Label	Cancer	Normal
Back	15	1
Left side	6	1
Right side	7	0
Top	22	48



EXTRACTION DES EMBEDDINGS DES IMAGES LABELLISÉES AVEC RESNET50

- Utilisation de ResNet50 en extracteur
- Scoring du nombre de couches (Régression logistique avec calcul du F1 score + `class_weight=« balanced »` + `StratifiedKFold`)


layer	mean_f1	std_f1
layer3	0.937778	0.081225
layer2	0.937374	0.051663
layer4	0.835873	0.131029

=> (70, 1024)

- Faible échantillons / nombreuses features
- => PCA nécessaire




RÉDUCTION DE DIMENSIONS



F1 Score PCA mean = 0.528

F1 Score PCA std = 0.138

=> Réduction
à 49 features




Les catégories sont bien séparées




APPLICATION DU MODÈLE SUR LE DATASET NON LABELLISÉ COMPLET


- Récupération des embeddings (même modèle)
- Scaler, PCA
- Reg. Log (même modèle) => 663 images vue top



CLUSTERING HDBSCAN DES IMAGES NON LABELLEES





Projection UMAP sur les labels forts => « normaux » et « cancer » sont assez bien séparés



Classification HDBSCAN => ARI = 0,426



CLUSTERING KMEANS DES IMAGES NON LABELLISEES




Le clustering KMeans retrouve largement la structure des classes avec un ARI de 0,722, ce qui justifie l'utilisation des clusters comme labels faibles pour les données non annotées.



TRAINING DES LABELS

FIABILISATION DES DONNÉES

- Optimisation des distances des données utilisées par rapport aux centroïdes
- On teste 80%, 90%, 100%
- => images mieux triées mais moins d'images



TRAINING DES LABELS FAIBLES ET FINE-TUNING


- split du jeu labellisé (80-20 soit 56 images train et 14 test, 5 folds)
- entraînement supervisé des images avec labels.
- training df labels faibles avec ResNet50
- => F1 score = 0,889
- Fine-tuning sur labels forts
- Test => F1 score = 0,889

	precision	recall	F1-score	support
0	0,9	1	0,95	9
1	1	0,8	0,89	5
accuracy			0,93	14
macro avg	0,95	0,9	0,92	14
weighted avg	0,94	0,93	0,93	14



COMPARAISON DES MODÈLES ET DES DEVICES

Apprentissage ResNet50




■ Utilisation de Google Colab:

- Exécution du même modèle ResNet50 10 iter sur un GPU T4 : F1 score 0,889

=> 30' / 2'30

- Exécution de 80 iter avec early stopping à 6 :
- F1 score 0,889

Apprentissage DenseNet201



- Exécution avec le modèle DenseNet201 sur 80 iter :
- F1 score 0,75



CONCLUSION — POINTS D'AMÉLIORATION

- Le clustering a été réalisé sur l'ensemble des données fortement labellisées afin de maximiser la qualité des pseudo-labels.
- La supervision des images labellisées donne le même score. Donc l'ajout des données faiblement labellisées n'apporte pas d'amélioration mesurable des performances.
- Pour ce cas présent DenseNet201 n'apporte pas d'amélioration
- Il faudrait plus d'images fortement labellisées => budget pour achat GPU ou PTF type Colab Pro (50€/mois)
- Tenter de modéliser aussi les autres vues (back, left-side, right-side). Dans l'idéal, plusieurs vues d'un même patient.
- Construire un pipeline pour analyser de nouvelles IRM.



ANNEXES — CLUSTERING LABELED / UNLABELED

