


LABELLISEZ ET APPLIQUEZ DES APPROCHES SEMI-SUPERVISÉES EN TRAITEMENT D'IMAGES

E. Houdin juillet 2026



OBJECTIF ET ORGANISATION

- 1- Explorer les images (IRM cérébrales) et extraire des caractéristiques visuelles via un modèle pré-entraîné ;
- 2- Appliquer des méthodes de clustering pour identifier des structures ou regroupements dans les données ;
- 3- Mettre en œuvre une méthode d'apprentissage semi-supervisé à partir des quelques étiquettes disponibles ;
- 4- Synthétiser vos résultats, formuler des recommandations, et les présenter à votre équipe projet.








1- EXPLORER LES IMAGES

- 100 images labellisées (50 images de cerveaux normaux et 50 de cerveaux avec cancer) et 108 images non labellisées mais triées par vue
- 1298 images non-labellisées
- 4 profiles : haut, arrière, gauche, droite
- Format : 512 * 512 en monochrome 3 canaux
- Format : 512, 512, 3 RGB (monochrome)

Normal brain labelled dataset




0161f9bf-fa93-4d02-80c3-18450d806642.jpg 934825cf-391835d472.jpg 47029726-d48794e.jpg 10548298-2ef84f03.jpg 975f-007c4fcb84a3.jpg



1- EXTRAIRE DES CARACTÉRISTIQUES VISUELLES

- Analyse labels et vues

Label	Cancer	Normal
Back	15	1
Left side	6	1
Right side	7	0
Top	22	48



2- EXTRACTION DES EMBEDDINGS DES IMAGES LABELLISÉES AVEC RESNET50

- Utilisation de ResNet50 en extracteur
- Scoring du nombre de couches (Régression logistique avec calcul du F1 score + `class_weight=« balanced »` + `StratifiedKFold`)


layer	mean_f1	std_f1
layer3	0.937778	0.081225
layer2	0.937374	0.051663
layer4	0.835873	0.131029

=> (70, 1024)

- Faible échantillons / nombreuses features
- => PCA nécessaire




RÉDUCTION DE DIMENSIONS



F1 Score PCA mean = 0.528

F1 Score PCA std = 0.138

=> Réduction
à 49 features




Les catégories sont bien séparées




APPLICATION DU MODÈLE SUR LE DATASET NON LABELLISÉ COMPLET


- Récupération des embeddings (même modèle)
- Scaler, PCA
- Reg. Log (même modèle) => 663 images vue top



CLUSTERING HDBSCAN DES IMAGES NON LABELLEES





« Normaux » et « cancer » sont assez bien séparés



Classification HDBSCAN => ARI = 0,426



CLUSTERING KMEANS DES IMAGES NON LABELLISEES



Le clustering KMeans retrouve largement la structure des classes avec un ARI de 0,722, ce qui justifie l'utilisation des clusters comme labels faibles pour les données non annotées.



TRAINING DES LABELS FAIBLES

- split du jeu labellisé (80-20 soit 56 images train et 14 test, 5 folds)
- entraînement supervisé des images avec labels.
- training df labels faibles avec ResNet50
- => F1 score = 0,889
- fine tuning sur labels forts
- Test => F1 score = 0,889

	precision	recall	F1-score	support
0	0,9	1	0,95	9
1	1	0,8	0,89	5
accuracy			0,93	14
macro avg	0,95	0,9	0,92	14
weighted avg	0,94	0,93	0,93	14





CONCLUSION — POINTS D'AMÉLIORATION

- Le clustering a été réalisé sur l'ensemble des données fortement labellisées afin de maximiser la qualité des pseudo-labels.
- Cette étape n'est pas utilisée directement pour l'évaluation du CNN.
- Le split a été fait uniquement à partir de la semi-supervision et fine tuning sur labels forts.
- La supervision des images labellisées donne le même score
- Donc l'ajout des données faiblement labellisées n'apporte pas d'amélioration mesurable des performances.
- Pour être plus précis il faudrait réaliser les folds avant le Kmeans
- Tenter de modéliser aussi les autres vues (back, left-side, right-side)



ANNEXES — CLUSTERING LABELED / UNLABELED



CLUSTERING OPTIMISATION

